CLASE PRÁCTICA DE 2 HORAS · ETL CON DATOS DE EUROSTAT

ETL: de datos crudos a datos útiles

Extract · Transform · Load

EL PROBLEMA

Los datos reales no llegan limpios

geo	2019	2020	2021
BE	6.21	6.71 p	6.26
EL	3.59 p	:	:
EU27_2020	4.70 d	5.02 d	4.86 d

Fragmento real del archivo de Eurostat educ_uoe_fine06 (gasto público en educación, % del PIB)

: significa «no disponible», no cero.

p, d son notas sobre la calidad del dato, pegadas al número.

EU27_2020 no es un país, es un agregado.

LA SOLUCIÓN

ETL tiene tres fases

E

Extract

Extraer los datos de la fuente.

Comprar los ingredientes

T

Transform

Limpiar y reorganizar los datos.

Cocinar

L

Load

Dejar el resultado donde se pueda usar.

Servir el plato

FASE 1 · EXTRACT

Los datos vienen de muchos sitios

- Archivos CSV y TSV
- JSON y XML
- Hojas de Excel
- Bases de datos
- APIs web
- Páginas web

Hoy: un archivo TSV de Eurostat, que leerás como una tabla con Python.

FASE 2 · TRANSFORM

Aquí están las decisiones

Convertir valores
De texto a número, separar el flag.

Valores ausentes
Dejarlos, eliminarlos o rellenarlos.

Seleccionar
Quedarse con los países y años de interés.

Unir tablas
Añadir el nombre del país a partir de su código.

Agregar
Medias por país, sumas por año.

Ordenar y clasificar
Quién es el primero y quién el último.

Cada transformación es una decisión, y cambia el resultado.

FASE 3 · LOAD

El resultado debe ir a un lugar útil

CSV

Universal y legible por todos.

Parquet

Compacto y conserva los tipos.

Base de datos

Se puede consultar y compartir.

Gráficos

Para comunicar el resultado.

Si otra persona puede repetir el proceso, el resultado es fiable.

FASE 3 · LOAD

Muchos lugares donde cargar el resultado

Archivos
CSV, Parquet, JSON, Excel

HOY: CSV, PARQUET, JSON

Base de datos relacional
SQLite, PostgreSQL, MySQL

HOY: SQLITE

Base de datos analítica
DuckDB, BigQuery, Snowflake

HOY: DUCKDB

Base de datos documental (NoSQL)
MongoDB, CouchDB, Firestore

HOY: DOCUMENTOS JSON

Data lake
Archivos Parquet en la nube (S3, Azure)

Clave-valor
Redis, DynamoDB: búsquedas rápidas por clave

Motor de búsqueda
Elasticsearch, OpenSearch: búsqueda de texto

Cuadros de mando e informes
Gráficos, Power BI, Tableau, una web

HOY: GRÁFICOS

Y muchos más: bases de datos de grafos (Neo4j), series temporales (InfluxDB), bases de datos vectoriales para IA...

UN EJEMPLO

Una celda, cinco columnas

ANTES (CRUDO)

`6.71 p`

Un número y una nota, dentro de un solo texto.

DESPUÉS (LIMPIO)

geo	country	year	value	flag
BE	Belgium	2020	6.71	p

Cada dato tiene su propia columna, y el número ya es un número.

LA ESTRUCTURA DE DATOS

Un DataFrame es una tabla con tipos y etiquetas

country	year	value
Denmark	2021	6.44
Spain	2021	4.69
Finland	2021	6.16

Gasto público en educación, % del PIB

Columnas: cada una tiene un único tipo (texto, entero, decimal).

Filas: cada una es una observación.

Etiquetas: filas y columnas tienen nombre.

Como una matriz con nombres, o una hoja de cálculo estricta.

CÓMO TRABAJAREMOS

Lee, ejecuta, prueba

Lee

Cada paso se explica antes de su código.

Ejecuta

Shift + Enter, en orden, desde arriba.

Prueba

Rellena los huecos de las celdas «Tu turno» y ejecuta la comprobación.

¿Un error en rojo? Lee la última línea.

PLAN DE LA SESIÓN

Dos horas, seis partes

Tiempo	Parte	Qué hacemos
0–15 min	Diapositivas e inicio	Concepto de ETL, abrir el notebook
15–30 min	1 · DataFrames	pandas en diez minutos
30–50 min	2 · Extract	Mirar los archivos, leer CSV y TSV
50–90 min	3 · Transform	Limpiar, decidir, comprobar, cazar errores
90–110 min	4 · Load	Guardar y hacer gráficos
110–120 min	5 · Reflexión	Repaso y cierre

ANTES DE ABRIR NADA

Escribe tu predicción

1. ¿Cuántos valores crees que faltan en el archivo?
2. ¿Qué país europeo gasta más en educación?
3. ¿Cómo crees que es el archivo original?

Escríbelo en una hoja de papel. Lo comprobaremos al final.