POSTGRADO EN DATA SCIENCE

Regresión Lineal

Laura Igual
ligual@ub.edu

Cómo realizar predicciones sobre cantidades del mundo real

— ¿Cómo cambia el volumen de ventas con cambios en el precio?

— ¿Cuánto tarda un trayecto según la hora del día?

— ¿Qué precio tendrá una vivienda dado su barrio, tamaño y ocupación?

— ¿Qué dosis de un fármaco corresponde a un paciente según su peso?

— ¿Cuántos clientes se esperan hoy?



Estructura común de los problemas de predicción del mundo real

Queremos predecir una variable respuesta (continua) a partir de una o más variables independientes.

VARIABLE RESPUESTA y

La cantidad que queremos predecir. También llamada variable dependiente o target.

Ejemplo: precio de una vivienda

COVARIABLES x_i

Las variables independientes que usamos como predictores. También llamadas regresores, features o predictores.
Ejemplo: superficie, barrio, número de habitaciones.

Objetivo de la regresión

Construir un modelo (fórmula) que permita predecir la respuesta a partir de las covariables.

El modelo de regresión lineal múltiple

El modelo más sencillo asume que la respuesta **y** depende **linealmente** de los predictores x_i:

$$\mathbf{y} = \beta_0 + \beta_1\mathbf{x_1} + \beta_2\mathbf{x_2} + \ldots + \beta_m\mathbf{x_m} + \varepsilon$$

β_i
Coeficientes

Parámetros del modelo que determinan la contribución de cada predictor a la respuesta.

$\mathbf{x_i}$
Predictores

Variables independientes (covariables, regresores o features).

ε
Término de error

Captura todos los factores que influyen en **y** y que el modelo no recoge (ruido irreducible).

La regresión lineal es la técnica para estimar los coeficientes **a** que mejor ajustan este modelo a los datos observados.

El modelo de regresión lineal múltiple (II)

Forma matricial compacta — equivalente a la expresión anterior:

$$\mathbf{y} = X\boldsymbol{\beta} + \varepsilon$$

$\mathbf{y}$
Target
Vector de respuestas (n × 1).

$\mathbf{X}$
Matriz de diseño
Matriz de features (n × m+1), con columna de unos para el intercepto β_0.

β
Coeficientes
Vector de coeficientes (m+1 × 1): β_0, β_1, …, β_m.

ε
Error
Vector de errores (n × 1).

REGRESIÓN VS CLASIFICACIÓN

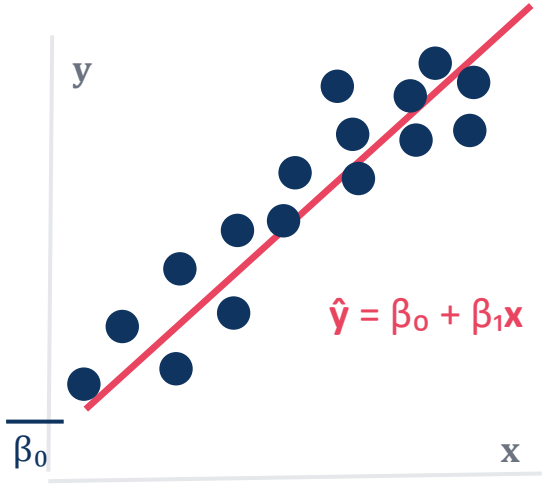
Salida numérica (precio, temperatura, dosis) → Regresión.
Salida categórica (spam/no-spam, enfermo/sano) → Clasificación.

El modelo de regresión lineal simple

Con un único predictor, el modelo describe la relación entre x y y mediante una recta:

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

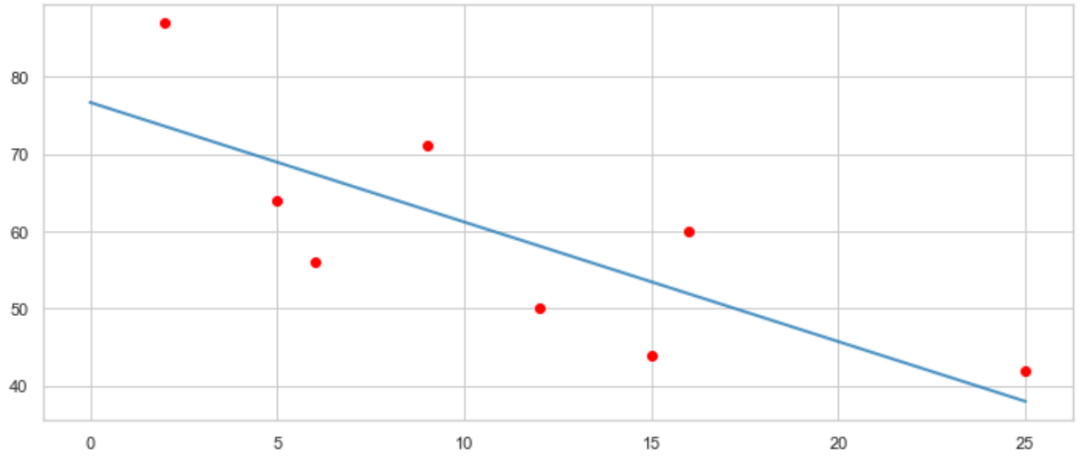
β_0 — Término constante o intercepto. Valor de y cuando x = 0.
β_1 — Pendiente. Cambio en y por unidad de incremento en x_1.
ε — Error irreducible (variabilidad no explicada por el modelo).

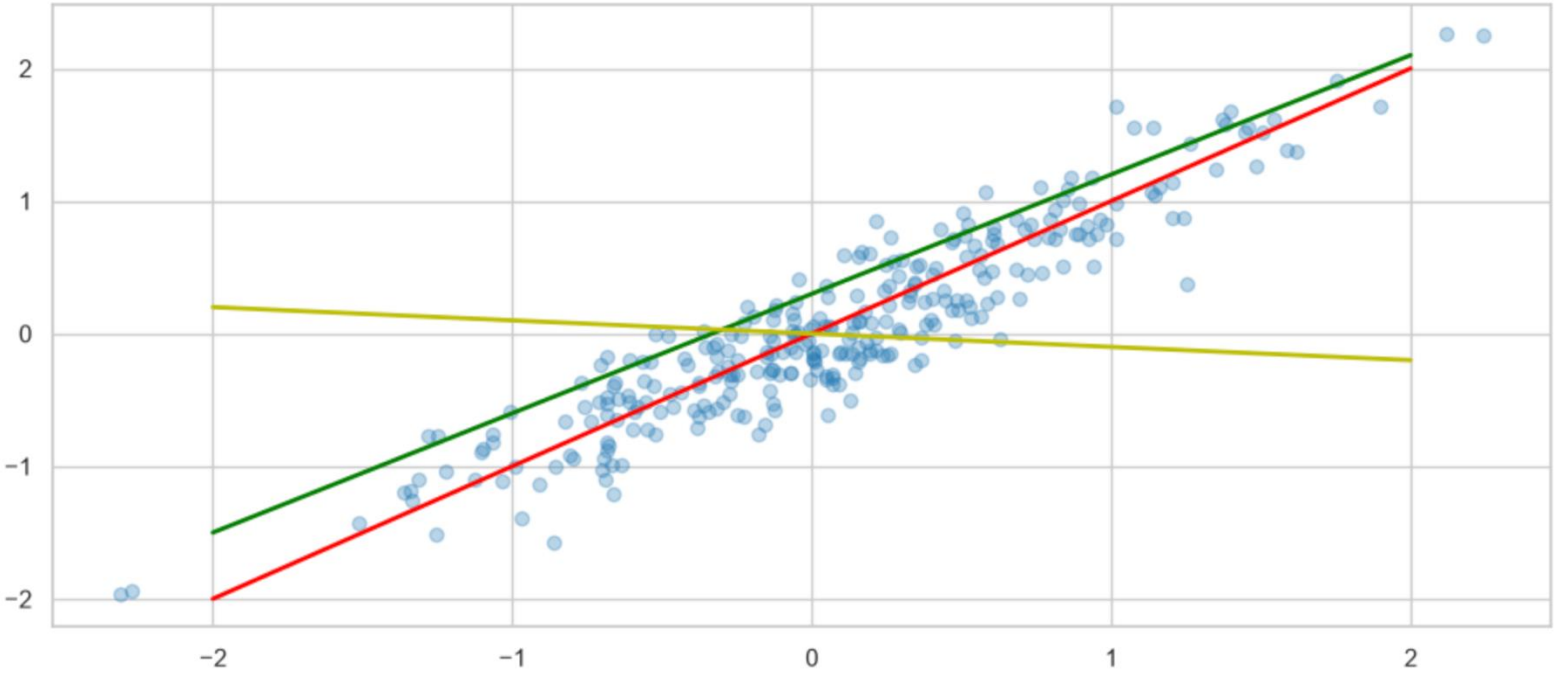


¿Depende el precio del seguro de la experiencia al conducir?

Dada la información de los precios mensuales del seguro de automóvil (**y**) y la experiencia al conducir en años ($\mathbf{x}_1$) de un conjunto de n=8 sujetos, podemos construir un modelo lineal para responder a esta pregunta.

Driving Experience (years)	Monthly Auto Insurance
5	64
2	87
12	50
9	71
15	44
6	56
25	42
16	60




2
1
0
−1
−2
−2
−1
0
1
2

OLS: Mínimos Cuadrados Ordinarios

Buscamos los coeficientes β que minimizan **la suma de los residuos al cuadrado** (RSS, Residual Sum of Squares):

$$\hat{\beta} = arg\ min_\beta\ \Sigma_i\ (y_i - x_i{}^T\beta - \beta_0)^2$$

La solución analítica (cuando **X** es invertible):

$$\hat{\beta} = (X^TX)^{-1}X^Ty$$

¿POR QUÉ CUADRADOS Y NO VALOR ABSOLUTO?

Los cuadrados son diferenciables en todo punto → solución cerrada.
Además, penalizan más los errores grandes, lo que suele ser deseable.

OLS: Mínimos Cuadrados Ordinarios

Enfoque popular por varias razones:

- Es computacionalmente barato calcular los coeficientes.
- Es más fácil de interpretar que modelos más sofisticados. En situaciones donde el objetivo es entender un modelo sencillo en detalle, en lugar de estimar la respuesta con precisión, puede ofrecer información valiosa sobre lo que el modelo captura.
- Robusto al ruido.
  - En situaciones donde hay mucho ruido, puede ser difícil encontrar la forma funcional “subyacente verdadera”, por lo que un modelo simple/restringido puede funcionar bastante bien en comparación con un modelo complejo, que se ve más afectado por el ruido.

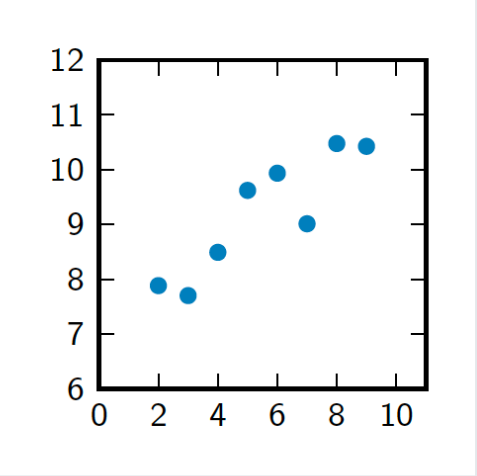
El modelo de regresión polinómica

A pesar de su nombre, la regresión lineal se puede utilizar para ajustar funciones no lineales. Un modelo de regresión lineal es lineal en los parámetros del modelo, no necesariamente en los predictores. Si añades transformaciones no lineales de tus predictores al modelo de regresión lineal, el modelo será no lineal en los predictores.

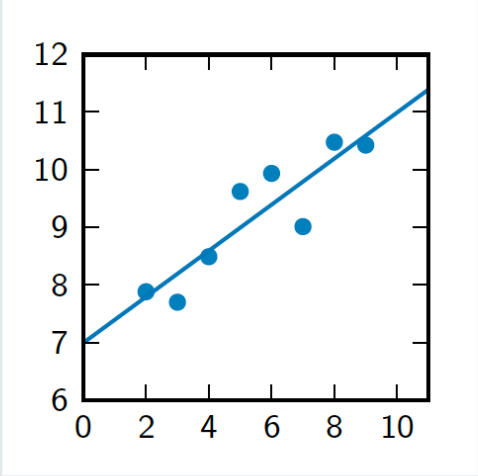
$$\mathbf{y} = a_0 + a_1\phi(\mathbf{x}_1) + \cdots + a_m\phi(\mathbf{x}_m)$$

La **regresión polinómica** es una técnica que modela la relación entre la respuesta y los predictores como un polinomio de orden n. Cuanto mayor sea el orden del polinomio, más funciones «onduladas» se pueden ajustar.

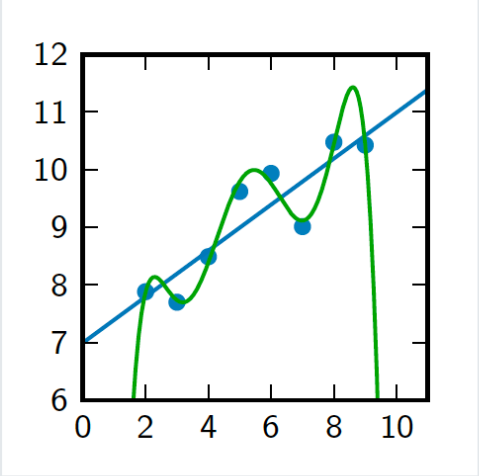
El uso de polinomios de orden superior tiene un precio: la **complejidad computacional** y el **sobreajuste**.



(a) A set of points with a simple linear relationship.

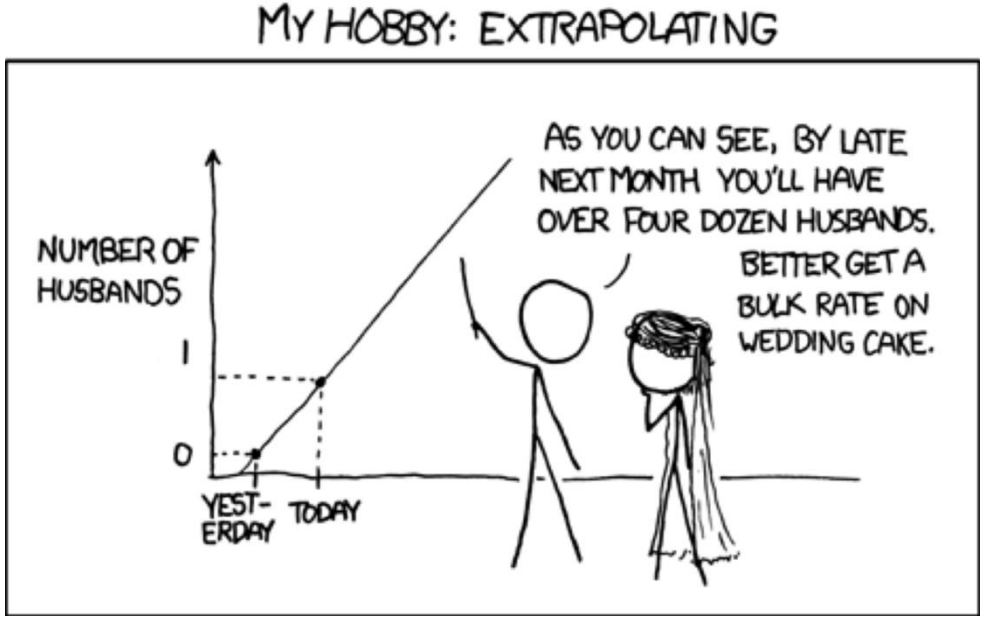


(b) The same set of points with a linear fit (blue).



(c) The same points with a 6th-order polynomial fit (green). As before, the linear fit is shown in blue.

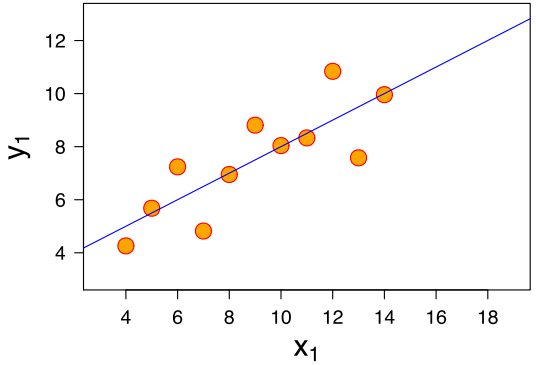
Atención con el uso

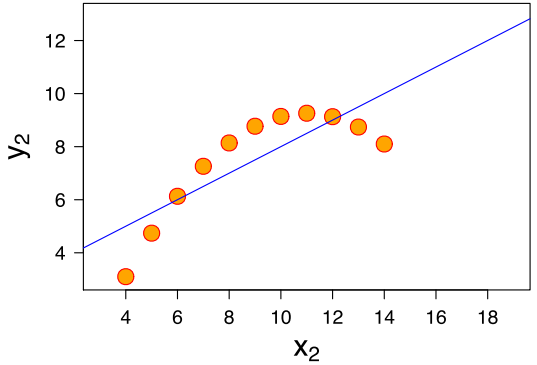


- Predecir y para un valor de x que está dentro del intervalo de puntos que vimos en los datos de entrenamiento se denomina **interpolación**.
- Predecir y para un valor de x que está fuera del rango de valores que vimos para x en los datos de entrenamineto se denomina **extrapolación**.
- Para conjuntos de datos reales, incluso si un ajuste lineal parece apropiado, debemos tener muchísimo cuidado con la extrapolación, ¡la cual a menudo puede dar lugar a predicciones falsas!

La importancia de visualizar los datos

El cuarteto de Anscombe:





Cuatro conjuntos de datos diferentes que tienen estadísticas descriptivas simples casi idénticas.

